

Autoencoders: Supresión de Ruido y Super Resolución

Jaime Ballesteros Domínguez José Gabriel Reyes Rodríguez
jaime.ballesteros101@alu.ulpgc.es jose.reyes121@alu.ulpgc.es

22 de enero de 2024

Resumen

En este trabajo se nos pedía crear un supresor de ruido de imágenes, es decir, añadir ruido a una serie de imágenes proporcionadas previamente para después intentar eliminar la mayor cantidad de ruido posible y comparar resultados. También se nos pedía hacer super resolución de imágenes, consistiendo esto en reducir los tamaños de las imágenes originales para después devolverlos a sus dimensiones originales. Al final, tanto el supresor de ruido como las super resoluciones de 14x14 y 7x7 devolvieron resultados satisfactorios.

1. Introducción

En la era actual de la información visual, nos enfrentamos al desafío de preservar la calidad y autenticidad de las imágenes, especialmente al considerar la proliferación de ruido y la necesidad de reescalarlas. Este trabajo se centra en la supresión de ruido y el reescalado de imágenes, utilizando el conjunto de datos MNIST. El propósito fundamental es lograr que las imágenes afectadas por el ruido conserven una apariencia visualmente aceptable, al mismo tiempo que garantizamos que el proceso de reescalado no comprometa la capacidad de identificar los números en ellas. Este enfoque busca equilibrar la mejora estética con la preservación de la información esencial en el contexto de la clasificación de dígitos.

2. Metodología y Experimentos

2.1. Supresión de Ruido

Para la tarea de la supresión de ruido, hemos optado por usar un AutoEncoder de capas convolutivas cuyas funciones de activación serán ReLu salvo en la última capa del decoder, que será una sigmoide. En cuanto a la función de pérdida, hemos usado la función de MSE.

En cuanto al dataset utilizado, hemos escogido el conjunto de datos del MNIST para realizar nuestros experimentos por sus características, ya que estas imágenes solo se encuentran en escalado de grises.

2.1.1. Entrenamiento

Para el entrenamiento, hemos añadido ruido a las imágenes antes de pasar la imagen por nuestro modelo para, posteriormente, calcular el error de la imagen generada respecto a la imagen original para afinar nuestro modelo.




Figura 1: Resultados en entrenamiento

En la Figura 1, podemos ver en la primera fila las imágenes originales del MNIST y en la segunda fila tenemos las imágenes generadas por nuestro AutoEncoder, que, como podemos apreciar, tienen un alto nivel de similitud.

2.1.2. Validación de resultados

Finalmente, para la validación, también le hemos añadido ruido a las imágenes antes de pasarlas por el modelo para obtener sus predicciones para posteriormente medir su grado de similitud con las imágenes originales mediante el Peak Signal-to-Noise Ratio (PSNR) para medirlo al ser una buena medida para medir la calidad de la reconstrucción en tareas de supresión de ruido.




Figura 2: Resultados en validación

En la Figura 2, podemos observar en la primera fila las imágenes suministradas al modelo y en la segunda fila las imágenes generadas por el modelo, que, junto con una medida de 0.5832 de PSNR, podemos ver que los resultados son bastante satisfactorios.

2.2. Super Resolución 14*14 a 28*28

Para la tarea de la super resolución de una imagen de 14*14 a 28*28, hemos optado por usar un AutoEncoder de capas convolutivas cuyas funciones de activación serán ReLu salvo en la última capa del decoder, que será una sigmoide. En cuanto a la función de pérdida, hemos usado la función de MSE.

El principal cambio hecho respecto al anterior modelo, es el ajuste de las capas del encoder para que funcione correctamente para imágenes de 14*14.

2.2.1. Entrenamiento

Para el entrenamiento, hemos escalado las imágenes para que sean 14*14 antes de pasar la imagen por nuestro modelo para, posteriormente, obtener una imagen 28*28 y compararla con la imagen original y calcular el error de la imagen generada respecto a la imagen original.




Figura 3: Resultados en entrenamiento

En la Figura 1, podemos ver en la primera fila las imágenes originales

y en la segunda fila tenemos las imágenes generadas por nuestro AutoEncoder, cuya similitud con las originales es bastante notable.

2.2.2. Validación

Para la validación, también hemos reescalado las imágenes a 14×14 antes de pasarlas por el modelo para obtener sus predicciones para posteriormente medir su grado de similitud con las imágenes originales mediante el Structural Similarity Index Measure (SSIM) para medirlo al ser una buena medida para medir la similitud estructural entre dos imágenes.




Figura 4: Resultados en validación

En la Figura 2, podemos observar en la primera fila las imágenes originales y en la segunda fila las imágenes generadas por el modelo, que, junto con una medida de 0.9656 de SSIM, podemos ver que los resultados son bastante satisfactorios.

2.3. Super Resolución 7×7 a 28×28

Para la tarea de la super resolución de una imagen de 7×7 a 28×28 , hemos optado por usar un AutoEncoder de capas convolutivas cuyas funciones de activación serán ReLu salvo en la última capa del decoder, que será una sigmoide. En cuanto a la función de pérdida, hemos usado la función de MSE.

Respecto al anterior modelo, aparte de ajustar las capas del encoder para que funcione correctamente para imágenes de 7×7 , también hemos aumentado la profundidad de nuestro modelo añadiéndole 2 nuevas capas ocultas.

2.3.1. Entrenamiento

Para el entrenamiento, hemos escalado las imágenes para que sean 7×7 antes de pasar la imagen por nuestro modelo para, posteriormente, obtener una imagen 28×28 y compararla con la imagen original y calcular el error de la imagen generada respecto a la imagen original.




Figura 5: Resultados en entrenamiento

En la Figura 1, podemos ver en la primera fila las imágenes originales y en la segunda fila tenemos las imágenes generadas por nuestro AutoEncoder, cuya similitud con las originales es bastante notable.

2.3.2. Validación

Para la validación, también hemos reescalado las imágenes a 7×7 antes de pasarlas por el modelo para obtener sus predicciones para posteriormente medir su grado de similitud con las imágenes originales mediante el Structural Similarity Index Measure (SSIM) para medirlo al ser una buena medida para medir la similitud estructural entre dos imágenes.




Figura 6: Resultados en validación

En la Figura 2, podemos observar en la primera fila las imágenes originales y en la segunda fila las imágenes generadas por el modelo, que, junto con una medida de 0.8547 de SSIM, podemos ver que los resultados son bastante satisfactorios pese a la baja resolución de las imágenes de entrada.

3. Conclusiones

El trabajo logró con éxito desarrollar un supresor de ruido y realizar super resoluciones utilizando AutoEncoders de capas convolutivas. Se utilizaron funciones de activación ReLu y la función de pérdida MSE. Los resultados en la supresión de ruido, medidos por PSNR, mostraron una

alta similitud entre las imágenes originales y las generadas. Las super resoluciones de imágenes de 14x14 a 28x28 y de 7x7 a 28x28 también fueron efectivas, con una notoria similitud estructural evaluada mediante SSIM. Estos logros indican que los métodos propuestos son robustos para preservar la calidad visual e información esencial, siendo útiles en la manipulación de imágenes en entornos de clasificación de dígitos y otras aplicaciones visuales.

A pesar de los logros en el desarrollo de un supresor de ruido y super resoluciones con AutoEncoders, se sugiere explorar la integración de Redes Generativas Adversarias (GAN) para mejorar la calidad visual y diversidad de las imágenes generadas. La competencia entre generador y discriminador en las GAN podría aumentar la fidelidad en la reconstrucción de imágenes, preservar detalles finos y generar imágenes más realistas. Esta dirección podría representar un avance significativo en la mejora continua de la calidad y autenticidad de las imágenes procesadas, especialmente en aplicaciones como la clasificación de dígitos y otras tareas visuales.